

ANDRIANARISON Fitiavana

FANOMEZANTSOA Gesy Louis Xavier

M1 Intelligence artificielle et data science

## Modélisation Probabiliste en Assurance Automobile

### I. Introduction et Objectifs

#### 1. Pourquoi modéliser en assurance automobile ?

L'assurance automobile doit « **prédire l'imprévisible** » : combien de sinistres vont survenir et combien ils vont coûter. La modélisation probabiliste permet de :

- **Calculer des primes justes** : pour chaque assuré
- **Estimer les réserves** nécessaires pour payer les sinistres futurs
- **Gérer les risques** de l'entreprise d'assurance

#### 2. Les 3 questions fondamentales

- **Le modèle de fréquence** : À quelle fréquence les sinistres surviennent-ils ?
- **Le modèle de sévérité** : Combien coûte chaque sinistre ?
- **Le modèle composé** : Quel sera le coût total par assuré ?

### ETAPE 1 : Identification des Variables Aléatoires

#### a. Variable N : Fréquence des sinistres

C'est le nombre de sinistres qu'un assuré va déclarer dans l'année

- **Type** : Variable discrète (0, 1, 2, 3, 4, ...)
- **Valeurs possibles** :  $N \in \{0, 1, 2, 3, \dots\}$
- **Interprétation** : "Combien de fois cet assuré va-t-il avoir un accident cette année ?"

#### Exemple concret :

- Assuré A :  $N = 0$  (aucun sinistre)
- Assuré B :  $N = 1$  (un sinistre)
- Assuré C :  $N = 3$  (trois sinistres)

#### b. Variable X : Coût individuel des sinistres

C'est le montant d'un sinistre donné

- **Type** Variable continue positive
- **Valeurs possibles** :  $X > 0$  (en euros)
- **Interprétation** : "Si un sinistre survient, combien va-t-il coûter ?"

#### Exemple concret :

- Sinistre léger :  $X = 800\text{€}$  (pare-choc rayé)
- Sinistre moyen :  $X = 5\,000\text{€}$  (collision avec dégâts)
- Sinistre grave :  $X = 25\,000\text{€}$  (accident avec blessés)

### c. Variable Y : Coût total annuel

C'est le coût total de tous les sinistres d'un assuré dans l'année

$$Y = X_1 + X_2 + \dots + X_N$$

### Interprétation :

- Si  $N = 0$  :  $Y = 0$  (aucun sinistre)
- Si  $N = 1$  :  $Y = X_1$  (un sinistre de coût  $X_1$ )
- Si  $N = 2$  :  $Y = X_1 + X_2$  (deux sinistres)
- Et ainsi de suite...

## ETAPE 2 : Modélisation de la Fréquence (Loi de Poisson)

### a) Pourquoi la loi de Poisson ?

La loi de Poisson est parfaite pour modéliser **des événements rares** qui surviennent **de manière aléatoire** dans le temps :

- Les sinistres automobiles sont relativement rares
- Ils surviennent de manière imprévisible
- Leur survenance est généralement indépendante

### b) Définition mathématique

Si  $N \sim \text{Poisson}(\lambda)$ , alors :  $P(N = k) = (\lambda^k \times e^{(-\lambda)}) / k!$

Où :

- $k$  = nombre de sinistres (0, 1, 2, 3, ...)
- $\lambda$  = paramètre d'intensité (nombre moyen de sinistres par an)
- $e$  = constante mathématique ( $\approx 2.718$ )
- $k!$  = factorielle de  $k$

### c) Interprétation du paramètre $\lambda$

$\lambda$  représente le nombre moyen de sinistres par assuré et par an

### Exemples :

- $\lambda = 0.1 \rightarrow$  En moyenne, 1 sinistre tous les 10 ans
- $\lambda = 0.2 \rightarrow$  En moyenne, 1 sinistre tous les 5 ans
- $\lambda = 0.5 \rightarrow$  En moyenne, 1 sinistre tous les 2 ans

## Propriétés

$E[N] = \lambda$  (Espérance = paramètre)

$\text{Var}[N] = \lambda$  (Variance = paramètre)

Plus  $\lambda$  est grand, plus la fréquence ET la variabilité des sinistres sont élevées.

## Estimation du paramètre $\lambda$

Méthode du Maximum de Vraisemblance :

$$\hat{\lambda} = (n_1 + n_2 + \dots + n_m) / m$$

- $n_1, n_2, \dots, n_m$  = nombre de sinistres de chaque assuré
- $m$  = nombre total d'assurés

## Exemple de calcul :

- 1000 assurés
- 150 sinistres au total
- $\hat{\lambda} = 150/1000 = 0.15$

## Interprétation :

En moyenne, chaque assuré a 0.15 sinistre par an.

## Calcul des probabilités

Pour  $\lambda = 0.2$  :

$$P(N = 0) = (0.2^0 \times e^{(-0.2)}) / 0! = 1 \times 0.819 / 1 = 81.9\%$$

$$P(N = 1) = (0.2^1 \times e^{(-0.2)}) / 1! = 0.2 \times 0.819 / 1 = 16.4\%$$

$$P(N = 2) = (0.2^2 \times e^{(-0.2)}) / 2! = 0.04 \times 0.819 / 2 = 1.6\%$$

## Interprétation :

- 81.9% des assurés n'auront aucun sinistre
- 16.4% des assurés auront exactement 1 sinistre
- 1.6% des assurés auront exactement 2 sinistres

## ETAPE 3 : Modélisation du Coût (Loi Log-Normale)

### Pourquoi la loi Log-Normale ?

Les coûts de sinistres ont des caractéristiques particulières :

**Toujours positifs** (on ne peut pas avoir un coût négatif)

**Asymétriques** : beaucoup de petits sinistres, peu de gros sinistres

**Queue lourde** : quelques sinistres très coûteux

### Définition mathématique

Si  $X \sim \text{LogNormale}(\mu, \sigma^2)$ , alors  $\log(X) \sim \text{Normale}(\mu, \sigma^2)$

**Fonction de densité :**

$$f(x) = (1 / (x \times \sigma \times \sqrt{2\pi})) \times \exp(-((\ln(x) - \mu)^2 / (2\sigma^2)))$$

**Paramètres :**

- $\mu$  = moyenne du logarithme des coûts
- $\sigma^2$  = variance du logarithme des coûts

### Interprétation des paramètres

**Paramètre  $\mu$  :**

- Plus  $\mu$  est grand, plus les coûts moyens sont élevés
- $\mu$  décale la distribution vers la droite

**Paramètre  $\sigma^2$  :**

- Plus  $\sigma^2$  est grand, plus la variabilité des coûts est élevée
- $\sigma^2$  contrôle la dispersion de la distribution

### Moments de la loi Log-Normale

**Espérance (coût moyen) :**

$$E[X] = \exp(\mu + \sigma^2/2)$$

**Variance (variabilité des coûts) :**

$$\text{Var}[X] = \exp(2\mu + \sigma^2) \times (\exp(\sigma^2) - 1)$$

**Pourquoi ces formules complexes ?**

**Propriété clé :** Si  $\log(X)$  suit une loi normale, alors  $X$  suit une loi log-normale.

**Transformation logarithmique :**

- **$\log(X)$**  est symétrique  $\rightarrow$  plus facile à analyser
- **$X$**  reste positif  $\rightarrow$  respecte la nature des coûts

### Estimation des paramètres

**Méthode du Maximum de Vraisemblance :**

$$\hat{\mu} = (1/n) \times \sum \ln(x_i)$$

$$\hat{\sigma}^2 = (1/n) \times \sum (\ln(x_i) - \hat{\mu})^2$$

Où :

- $x_i$  = coût du i-ème sinistre
- $n$  = nombre de sinistres observés
- $\ln$  = logarithme naturel

**Exemple de calcul :**

Sinistres observés : 1000€, 2500€, 800€, 15000€, 3200€

$$\ln(1000) = 6.908$$

$$\ln(2500) = 7.824$$

$$\ln(800) = 6.685$$

$$\ln(15000) = 9.616$$

$$\ln(3200) = 8.071$$

$$\hat{\mu} = (6.908 + 7.824 + 6.685 + 9.616 + 8.071) / 5 = 7.821$$

**Calcul de  $\hat{\sigma}^2$  :**

$$\hat{\sigma}^2 = [(6.908-7.821)^2 + (7.824-7.821)^2 + \dots + (8.071-7.821)^2] / 5$$

$$\hat{\sigma}^2 = [0.833 + 0.000 + 1.290 + 3.223 + 0.063] / 5 = 1.082$$

**Calcul du coût moyen**

**Avec  $\hat{\mu} = 7.821$  et  $\hat{\sigma}^2 = 1.082$  :**

$$E[X] = \exp(7.821 + 1.082/2) = \exp(8.362) = 4\,347\text{€}$$

**Interprétation :** Le coût moyen d'un sinistre est d'environ 4 347€.

#### ÉTAPE 4 : Modèle Composé (Coût Total)

**Concept du modèle composé**

**Le coût total Y combine :**

1. **La fréquence** des sinistres (combien ?)
2. **La sévérité** des sinistres (combien chacun coûte ?)

$$Y = X_1 + X_2 + \dots + X_N$$

Où :

- $N \sim \text{Poisson}(\lambda)$  : nombre de sinistres
- $X_1, X_2, \dots \sim \text{Log Normale}(\mu, \sigma^2)$  : coût de chaque sinistre

### Moments du modèle composé

#### Espérance (coût total moyen) :

$$E[Y] = E[N] \times E[X] = \lambda \times E[X]$$

#### Variance (variabilité du coût total) :

$$\text{Var}[Y] = E[N] \times \text{Var}[X] + \text{Var}[N] \times (E[X])^2$$

$$\text{Var}[Y] = \lambda \times \text{Var}[X] + \lambda \times (E[X])^2$$

#### Interprétation des formules

##### Espérance $E[Y] = \lambda \times E[X]$ :

- Si  $\lambda = 0.2$  et  $E[X] = 4000\text{€}$
- Alors  $E[Y] = 0.2 \times 4000\text{€} = 800\text{€}$
- **Signification** : En moyenne, chaque assuré coûte 800€ par an

##### Variance $\text{Var}[Y] = \lambda \times \text{Var}[X] + \lambda \times (E[X])^2$ :

- **Premier terme  $\lambda \times \text{Var}[X]$**  : Variabilité due aux coûts variables
- **Second terme  $\lambda \times (E[X])^2$**  : Variabilité due à la fréquence variable

#### Exemple complet de calcul

##### Données :

- $\lambda = 0.15$  (fréquence)
- $\mu = 8.0, \sigma^2 = 1.2$  (paramètres log-normaux)

##### Étape 1 : Calcul des moments de X

$$E[X] = \exp(8.0 + 1.2/2) = \exp(8.6) = 5\,431\text{€}$$

$$\text{Var}[X] = \exp(2 \times 8.0 + 1.2) \times (\exp(1.2) - 1)$$

$$= \exp(17.2) \times (3.32 - 1)$$

$$= 26\,903\,134 \times 2.32 = 62\,415\,271\text{€}^2$$

##### Étape 2 : Calcul des moments de Y

$$E[Y] = 0.15 \times 5\,431 = 815\text{€}$$

$$\text{Var}[Y] = 0.15 \times 62\,415\,271 + 0.15 \times (5\,431)^2$$

$$= 9\,362\,291 + 4\,417\,854$$

$$= 13\,780\,145\text{€}^2$$

### Écart-type de Y :

$$\sigma[Y] = \sqrt{13\,780\,145} = 3\,712\text{€}$$

### Interprétation :

- Coût moyen par assuré : 815€
- Écart-type : 3 712€
- La plupart des assurés coûteront entre 0€ et 4 527€ (815 + 3712)

---

## ÉTAPE 5 : Provisionnement et Réserves

### Objectif du provisionnement

L'assureur doit **mettre de l'argent de côté** pour payer :

1. Les sinistres déjà déclarés mais pas encore payés
2. Les sinistres qui vont être déclarés plus tard
3. Les ajustements sur les estimations actuelles

### Types de reserves

#### RBNS (Reported But Not Settled)

**Définition** : Réserves pour les sinistres déclarés mais non réglés

#### Calcul simple :

$$\text{RBNS} = \Sigma (\text{Estimation du coût final} - \text{Montant déjà payé})$$

#### Exemple :

- Sinistre A : Estimation 5000€, Payé 2000€ → RBNS = 3000€
- Sinistre B : Estimation 3000€, Payé 0€ → RBNS = 3000€
- **Total RBNS = 6000€**

#### IBNR (Incurred But Not Reported)

**Définition :** Réserves pour les sinistres survenus mais non déclarés

**Problème :** Comment estimer des sinistres qu'on ne connaît pas encore ?

**Méthode statistique :**

$$\text{IBNR} = E[Y] \times \text{Nombre d'assurés} - \text{Sinistres déjà connus}$$

**Exemple :**

- 10 000 assurés
- $E[Y] = 800\text{€}$  par assuré
- Coût théorique total = 8 000 000€
- Sinistres déjà déclarés = 6 500 000€
- $\text{IBNR} = 8\,000\,000\text{€} - 6\,500\,000\text{€} = 1\,500\,000\text{€}$

**IBNER (Incurred But Not Enough Reserved)**

**Définition :** Ajustement car nos estimations peuvent être **insuffisantes**

**Méthode simple**

$$\text{IBNER} = \text{Pourcentage} \times (\text{RBNS} + \text{IBNR})$$

**Exemple avec 5% d'ajustement :**

$$\text{IBNER} = 0.05 \times (6\,000\,000\text{€} + 1\,500\,000\text{€}) = 375\,000\text{€}$$

**Méthode Chain Ladder (Avancée)**

**Principe :** Analyser comment les sinistres **se développent dans le temps**

**Triangle de développement :**

Année	Mois 1	Mois 2	Mois 3	Mois 6	Mois 12
2021	100	120	135	145	150
2022	110	130	140	155	???
2023	105	125	138	???	???
2024	115	135	???	???	???

**Facteurs de développement :**

$$f_{1-2} = 120/100 = 1.20$$

$$f_{2-3} = 135/120 = 1.125$$

$$f_{3-6} = 145/135 = 1.074$$

$$f_{6-12} = 150/145 = 1.034$$



### **Projection pour 2022 :**

Mois 12 =  $155 \times 1.034 = 160\text{€}$

### **ÉTAPE 6 : Calcul des Primes**

#### **Structure d'une prime d'assurance**

**Prime commerciale = Prime pure + Chargements**

#### **Prime pure**

**Définition :** Coût technique pur du risque

#### **Formule :**

Prime pure =  $E[Y] = \lambda \times E[X]$

#### **Exemple :**

- $\lambda = 0.15$ ,  $E[X] = 4000\text{€}$
- **Prime pure =  $0.15 \times 4000\text{€} = 600\text{€}$**

#### **Chargements**

Les chargements couvrent :

1. **Frais de gestion** (15-20%)
2. **Commissions** (10-15%)
3. **Frais généraux** (5-10%)
4. **Marge de sécurité** (5-10%)
5. **Profit** (5-10%)

#### **Exemple de calcul :**

Prime pure : 600€

Chargements :  $40\% \times 600\text{€} = 240\text{€}$

Prime commerciale :  $600\text{€} + 240\text{€} = 840\text{€}$

#### **Tarification par segment**

**Principe :** Calculer  $\lambda_i$  spécifique à chaque profil d'assuré

**Régression de Poisson :**

$$\log(\lambda_i) = \beta_0 + \beta_1 \times \text{Âge} + \beta_2 \times \text{Sexe} + \beta_3 \times \text{Expérience} + \dots$$

**Exemple :**

- Jeune conducteur (22 ans, homme) :  $\lambda = 0.35$
- Conducteur expérimenté (45 ans, femme) :  $\lambda = 0.08$
- **Primes différentes selon le profil**

## **ÉTAPE 7 : Système Bonus-Malus**

**Objectif**

**Ajuster la prime** en fonction de l'expérience de sinistralité de l'assuré

**Fonctionnement classique**

**Coefficients standards :**

- Coefficient initial : 100%
- Bonus annuel (0 sinistre) : -5%
- Malus (1 sinistre) : +25%
- Malus (2 sinistres) : +50%

**Exemple d'évolution :**

Année 1 : 100% (début)

Année 2 : 95% (0 sinistre → bonus)

Année 3 : 90% (0 sinistre → bonus)

Année 4 : 112.5% (1 sinistre → malus sur 90%)

Année 5 : 107% (0 sinistre → bonus sur 112.5%)

**Calcul de la prime finale**

**Formule complète :**

Prime finale = Prime de base  $\times$  Coefficient bonus-malus

### **Exemple :**

- Prime de base : 800€
- Coefficient : 90%
- **Prime finale :  $800\text{€} \times 0.90 = 720\text{€}^{**}$**

## **ÉTAPE 8 : Validation et Tests**

### **Tests statistiques essentiels**

#### **Test du Chi-2 pour la fréquence**

##### **Objectif :**

Vérifier si les données suivent bien une loi de Poisson

##### **Hypothèses :**

- $H_0$  : Les données suivent une loi de Poisson
- $H_1$  : Les données ne suivent pas une loi de Poisson

##### **Statistique de test :**

$$\chi^2 = \sum ((\text{Observé} - \text{Attendu})^2 / \text{Attendu})$$

#### **Test de Kolmogorov-Smirnov pour les coûts**

**Objectif :** Vérifier si les coûts suivent bien une loi log-normale

**Principe :** Comparer la distribution empirique avec la distribution théorique

#### **Backtesting**

**Principe :** Tester le modèle sur des données historiques

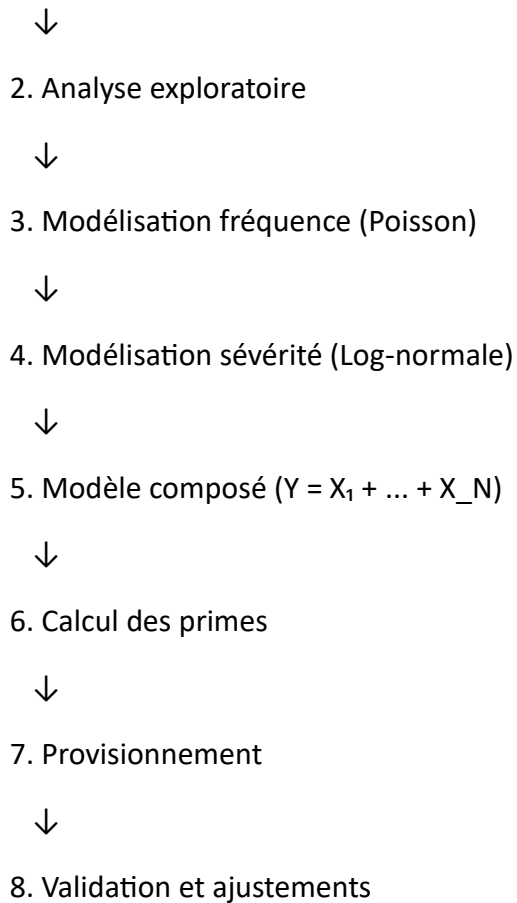
##### **Méthode :**

1. Estimer les paramètres sur les années N-3 à N-1
2. Prédire l'année N
3. Comparer prédictions vs réalité
4. Calculer les erreurs de prédiction

## **Synthèse : Vue d'ensemble du processus**

### **Cycle complet de modélisation**

1. Collecte des données



### Objectifs atteints

#### Pour l'assureur :

- Primes équitables et compétitives
- Réserves adéquates
- Maîtrise du risque

#### Pour l'assuré :

- Prime adaptée à son profil de risque
- Couverture garantie en cas de sinistre

### Points clés à retenir

1. **La modélisation probabiliste** est la base de toute tarification d'assurance
2. **Chaque formule** a un sens concret et une utilité pratique
3. **La validation** est essentielle pour s'assurer de la qualité du modèle
4. **L'ajustement continu** permet d'améliorer les prédictions

## **Pour aller plus loin**

### **Sujets avancés**

- Modèles de régression avec covariables
- Méthodes de réassurance
- Modèles de dépendance entre fréquence et sévérité
- Intelligence artificielle en actuariat

### **Applications pratiques**

- Tarification automobile
- Assurance habitation
- Assurance santé
- Analyse de rentabilité